ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

BÁO CÁO BÀI TẬP

DỊCH MÁY ANH - VIỆT

Transformer và Seq2Seq

với Luong Attention

Thực nghiệm trên IWSLT 2015

Sinh viên:	NGUYỄN THỊ HIỀN
Mã sinh viên:	24022321
Lớp học phần:	INT3406# 3
Đề bài:	ASM Machine Translation
Mã nguồn:	24022321_ASM-Machine-Translation
Kết quả thực nghiệm:	Google Drive

Tóm tắt.

Báo cáo trình bày bản tái triển khai bằng PyTorch của hai hệ thống dịch máy Anh–Việt: Transformer Encoder–Decoder và Seq2Seq Bi-LSTM với Luong Attention. Hai mô hình dùng chung dữ liệu IWSLT 2015, tokenizer BPE và quy trình đánh giá. Trên 1.268 câu của tập tst2013, Transformer đạt 29,78 BLEU và Seq2Seq đạt 28,18 BLEU với beam size 5. Checkpoint được chọn theo dev BLEU; mọi điểm test trong báo cáo lấy từ các lượt chạy thực tế. Phân tích đi kèm làm rõ ảnh hưởng của giải mã, thời gian train, lỗi dịch và giới hạn của phép so sánh.

Hà Nội, tháng 11 năm 2026

1. Mục tiêu và phạm vi triển khai

Bài tập yêu cầu xây dựng hệ thống dịch Anh–Việt, tái triển khai hai trường hợp từ notebook `demo_transformer.ipynb` và kho TensorFlow NMT, sau đó so sánh trên cùng corpus IWSLT 2015. Báo cáo chọn Transformer cho trường hợp thứ nhất và Seq2Seq với attention cho trường hợp thứ hai.

Transformer dùng self-attention để biểu diễn tương tác giữa các vị trí trong chuỗi [1]. Seq2Seq dùng encoder–decoder LSTM, bổ sung attention để truy cập các trạng thái nguồn khi sinh từng token đích [2]. Cả hai được triển khai trong cùng một project PyTorch, dùng chung các module dữ liệu, loss, checkpoint, giải mã và metric.

Phạm vi tái triển khai. Đây là tái triển khai các họ kiến trúc, không phải thực thi nguyên kho TensorFlow NMT [3], cũng không khẳng định giữ nguyên mọi siêu tham số của notebook mẫu. BPE, Adam/AdamW, label smoothing, target weight tying, bridge trạng thái và cấu hình mô hình là các lựa chọn của bản thực nghiệm. Không dùng mô hình tiền huấn luyện, back-translation hoặc corpus song ngữ bổ sung.

1.1 Câu hỏi thực nghiệm

1. Với cùng tập dữ liệu và phép đo, hai mô hình đạt chất lượng dịch như thế nào?
2. Beam search thay đổi BLEU và chrF2 so với greedy ra sao?
3. Chất lượng đạt được phải đánh đổi với số tham số và chi phí train như thế nào?
4. Những kiểu lỗi nào vẫn xuất hiện dù điểm toàn tập được cải thiện?

1.2 Nguồn số liệu và tính tái lập

Số liệu được lấy từ hai notebook có output đã chạy, cùng các file `comparison.json`, `comparison.csv` và hai biểu đồ do chương trình so sánh xuất ra. Hai run tương ứng là:

- Transformer: `transformer_20261110_174642`.
- Seq2Seq: `seq2seq_20261110_194635`.

Mỗi mô hình hiện có một run được báo cáo. Vì số tham số, optimizer và số epoch thực chạy khác nhau, đây là so sánh hai hệ thống dưới chung quy trình dữ liệu/đánh giá, chưa phải thí nghiệm kiểm soát duy nhất biến kiến trúc. Kết quả không được diễn giải như ưu thế có ý nghĩa thống kê qua nhiều seed.

2. Dữ liệu và tiền xử lý

2.1 Phân chia dữ liệu

IWSLT 2015 English-Vietnamese gồm các cặp câu song ngữ từ bài nói TED. Thí nghiệm giữ nguyên phân chia train, tst2012 và tst2013 trong gói dữ liệu được cung cấp.

Bảng 1: Kích thước dữ liệu trước và sau bước lọc của project.

Tập	Vai trò	Cặp gốc	Cặp sử dụng
Train	Cập nhật tham số	133.317	132.009
Dev / tst2012	Chọn checkpoint, early stopping	1.553	1.553
Test / tst2013	Đánh giá cuối	1.268	1.268

Train loại 1.308 cặp có ít nhất một phía rỗng hoặc độ dài vượt 100 token sau thêm token đặc biệt. Chuỗi nguồn thêm EOS; chuỗi đích thêm BOS và EOS. Dev/test không lọc câu dài, tránh chỉ đánh giá trên phần dữ liệu dễ.

2.2 Tokenizer và mini-batch

Hai tokenizer SentencePiece BPE có kích thước 8.000 mỗi phía và chỉ được học trên train. Mã đặc biệt: PAD=0, UNK=1, BOS=2, EOS=3. Văn bản giữ hoa/thường và dấu câu theo corpus Moses-tokenized; normalization của SentencePiece là `identity`. Không thêm bước phân đoạn từ tiếng Việt.

Sampler ghép các câu gần độ dài để giảm padding. Ngân sách batch là 4.096 với ràng buộc xấp xỉ $B \max_i\{|x_i|, |y_i|\} \leq 4096$, trong đó độ dài gồm token đặc biệt. Vì câu dài ngắn khác nhau, số câu trong mỗi batch thay đổi. Ngân sách evaluation là 2.048; gradient accumulation bằng 1.

2.3 Trùng lặp và giới hạn dữ liệu

Thống kê trên các cặp câu gốc sau `strip` ghi nhận 12 cặp trùng train–dev, 12 cặp train–test và 3 cặp dev–test. Trong từng split có lần lượt 1.145, 2 và 7 cặp trùng. Thí nghiệm giữ nguyên split chuẩn và công bố hiện tượng này; không gọi dữ liệu là đã khử trùng hoàn toàn. Các phép đo cần được hiểu trong phạm vi corpus gốc, không phải trên một test set đã loại mọi trùng lặp.

3. Kiến trúc hai mô hình

3.1 Transformer Encoder-Decoder

Transformer dùng embedding 512 chiều, positional encoding sin/cos, 6 lớp encoder và 6 lớp decoder. Mỗi lớp có 4 attention heads, FFN 1.024 chiều với ReLU. Các sublayer dùng Pre-Norm và residual:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V, \tag{1}$$

$$x' = x + \text{Dropout}\big(F(\text{LayerNorm}(x))\big). \tag{2}$$

M che các vị trí padding và, với decoder self-attention, che token tương lai. Decoder còn có cross-attention lên biểu diễn nguồn. Positional encoding tại vị trí p là

$$PE_{p,2i} = \sin\left(p/10000^{2i/d}\right), \qquad PE_{p,2i+1} = \cos\left(p/10000^{2i/d}\right). \tag{3}$$

Dropout chính là 0,3, attention dropout là 0,1. Ma trận output được buộc chung trọng số với embedding đích; embedding nguồn và đích không buộc chung. Tổng tham số là **39.737.344**.

3.2 Seq2Seq Bi-LSTM với Luong Attention

Encoder có một lớp Bi-LSTM, hidden 512 cho mỗi chiều; biểu diễn nối có kích thước 1.024 và được chiếu về 512. Decoder có hai lớp LSTM hidden 512. Bridge tuyến tính kết hợp tanh chuyển trạng thái cuối encoder sang trạng thái khởi tạo decoder.

Bản cài đặt dùng dạng general Luong với hệ số vô hướng học được g, không phải phép chia cố định cho $\sqrt{d}$:

$$e_{t,i} = g\, s_t^\top W_a m_i, \qquad \alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_{j\in\mathcal{V}_x}\exp(e_{t,j})}, \tag{4}$$

$$c_t = \sum_i \alpha_{t,i} m_i, \qquad \widetilde{s}_t = \tanh\big(W_c[c_t; s_t]\big). \tag{5}$$

Ở đây m_i là memory nguồn đã chiếu; $\mathcal{V}_x$ chỉ gồm vị trí không PAD. Input feeding nối $\widetilde{s}_{t-1}$ vào embedding đầu vào ở bước kế tiếp. Cách này giúp decoder sử dụng thông tin attention trước đó, nhưng vẫn phải tính tuần tự theo thời gian. Dropout là 0,2; embedding đích buộc trọng số với output. Tổng tham số là **20.005.889**.

3.3 Các tối ưu triển khai

Transformer sử dụng SDPA của PyTorch cho attention. Khi giải mã, chỉ hidden state ở vị trí cuối được chiếu lên từ vựng; prefix vẫn được tính lại, chưa có KV cache. Resume nạp checkpoint qua CPU và giải phóng bản checkpoint sau khôi phục để tránh giữ tensor dư trên GPU. AMP được bật khi train; riêng các phép LSTM của Seq2Seq giữ FP32 để đồng nhất kiểu trạng thái, còn các phép chiếu phù hợp dùng autocast. Toàn bộ đánh giá cuối dùng FP32.

4. Thiết lập huấn luyện và đánh giá

Bảng 2: Cấu hình huấn luyện được sử dụng trong project.

Thành phần	Transformer	Seq2Seq
Optimizer	AdamW	Adam
Learning rate	Inverse-square-root	10^{-3}, cố định
Tham số bổ sung	$\beta = (0{,}9; 0{,}98)$, $\epsilon = 10^{-9}$	Mặc định Adam của PyTorch
Weight decay	10^{-4}	0
Warmup / scale	4.000 updates / 2	Không áp dụng
Clip norm	1,0	5,0
Seed / smoothing	42 / 0,1	42 / 0,1
Epoch tối đa / patience	30 / 5	30 / 5
Precision khi train	AMP	AMP, LSTM giữ FP32
Thiết bị	Tesla T4	Tesla T4

Notebook ghi PyTorch 2.14.1+cu130 và 41 kiểm thử pass trên T4. Bộ kiểm thử bao gồm mask, forward/backward, giải mã và resume; kết quả kiểm thử không đồng nghĩa với bảo đảm chất lượng dịch.

4.1 Loss, scheduler và chọn checkpoint

Huấn luyện dùng teacher forcing với cross-entropy và label smoothing $\varepsilon = 0{,}1$. Loss chia theo tổng số token đích khác PAD. Chỉ số NLL hiển thị không dùng smoothing:

$$\mathrm{NLL} = -\frac{1}{N} \sum_{t:y_t \neq \mathrm{PAD}} \log p_\theta(y_t \mid y_{<t}, x). \tag{6}$$

Scheduler Transformer dùng số optimizer updates thành công u:

$$\eta(u) = 2\, d_{\text{model}}^{-1/2} \min\left(u^{-1/2}, u\, 4000^{-3/2}\right). \tag{7}$$

Một số bước AMP có thể bị GradScaler bỏ qua khi gradient không hữu hạn; scheduler chỉ tiến khi update thành công. Checkpoint `best.pt` được chọn bằng dev BLEU greedy chưa làm tròn. Early stopping kích hoạt sau 5 epoch liên tiếp không cải thiện. `last.pt` lưu trạng thái để resume ở ranh giới epoch.

4.2 Giải mã và phép đo

Greedy chọn token có xác suất cao nhất ở mỗi bước. Beam search giữ tối đa 5 nhánh còn sống, lưu các giả thuyết hoàn tất và xếp hạng bằng log-probability chuẩn hóa độ dài:

$$S(y) = \frac{\sum_{t=1}^{L} \log p_\theta(y_t \mid y_{<t}, x)}{((5+L)/6)^{1,0}}. \tag{8}$$

L tính EOS nếu có và không tính BOS. BOS/PAD bị chặn trước log-softmax. Cả hai mô hình dùng tối đa 160 token mới. Các bản dịch được giải mã khỏi BPE trước khi chấm.

BLEU được tính bằng SacreBLEU 2.6.0 trên văn bản Moses-tokenized, `tokenize="none"`, phân biệt hoa/thường và smoothing `exp`; không báo điểm trên BPE token IDs. Signature là:

```
nrefs:1|case:mixed|eff:no|tok:none|smooth:exp|version:2.6.0
```

chrF2 dùng cùng văn bản, bậc ký tự tối đa 6, không dùng word n-gram; đây không phải chrF2 trên văn bản detokenized. Công bố cách chuẩn hóa và metric là cần thiết để đối chiếu BLEU [4].

5. Kết quả thực nghiệm

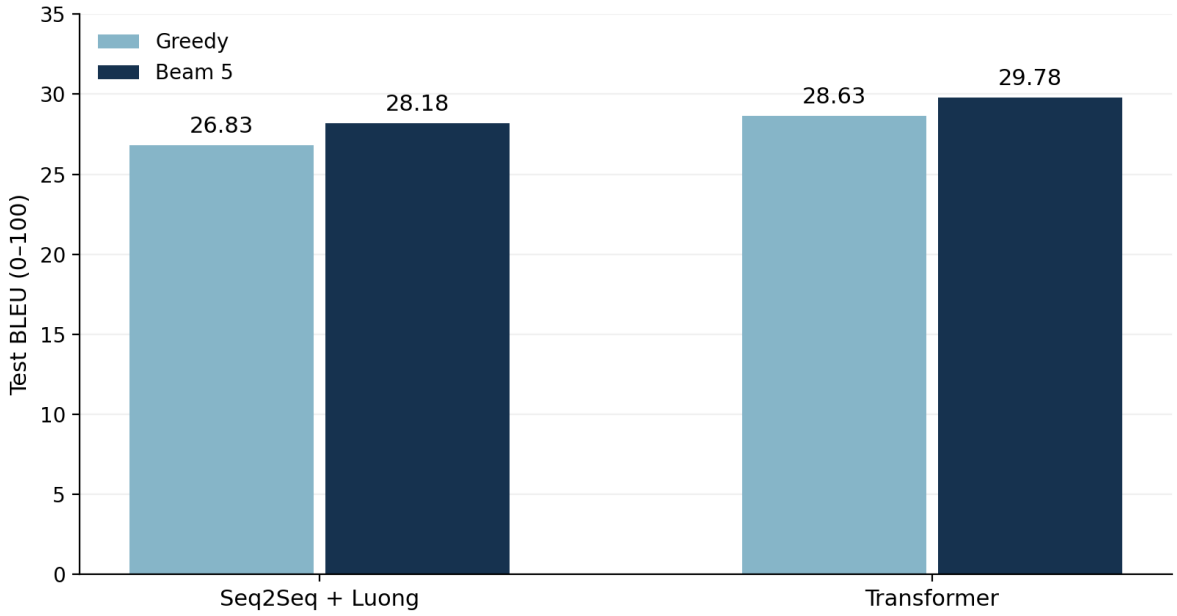
5.1 Chất lượng trên tập test

Bảng 3: Kết quả test tst2013; cùng 1.268 câu và cùng quy ước chấm.

Mô hình	Giải mã	BLEU	chrF2	Câu chạm trần
Transformer	Greedy	28,63	47,75	0
Transformer	Beam 5	**29,78**	**48,70**	0
Seq2Seq	Greedy	26,83	46,05	1
Seq2Seq	Beam 5	28,18	47,24	1

Transformer cao hơn Seq2Seq 1,80 BLEU với greedy và 1,60 BLEU với beam 5. Beam 5 cải thiện 1,15 BLEU ở Transformer và 1,36 BLEU ở Seq2Seq. Đồng thời, chrF2 cũng tăng ở cả hai hệ thống. Các chênh lệch được tính từ giá trị đầy đủ trước khi làm tròn.

Seq2Seq có một câu không sinh EOS trước trần 160 token trong mỗi chế độ; câu này vẫn được giữ trong phép chấm. Không suy diễn rằng mọi câu dịch đều đúng chỉ từ một chỉ số tổng hợp.



Hình 1: BLEU test, biểu đồ vẽ lại từ số liệu comparison.json của hai run.

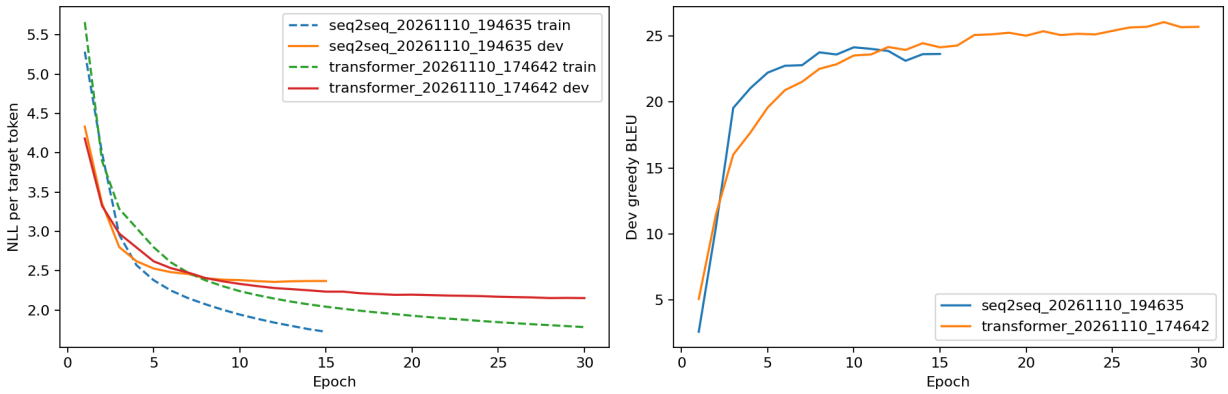
5.2 Quá trình hội tụ

Bảng 4: Epoch hoàn thành và checkpoint được chọn theo dev BLEU.

Mô hình	Epoch đã chạy	Best epoch	Best dev BLEU
Transformer	30	28	26,07
Seq2Seq	15	10	24,16

Seq2Seq đạt dev BLEU tốt nhất ở epoch 10. Các epoch 11–15 không vượt mốc này nên run dừng sớm. NLL train tiếp tục giảm từ 1,9434 ở epoch 10 xuống 1,7252 ở epoch 15, nhưng dev BLEU không tăng tương ứng. Đây là lý do lựa chọn checkpoint theo dev thay vì lấy model cuối hoặc model có train loss nhỏ nhất.

Transformer tiếp tục cải thiện qua nhiều epoch và đạt đỉnh dev BLEU 26,07 ở epoch 28. Hai epoch cuối giảm xuống 25,69 và 25,71. Run kết thúc do đạt giới hạn 30 epoch, **không phải do early stopping**; chưa đủ bằng chứng để khẳng định đã đạt giới hạn chất lượng tuyệt đối.



Hình 2: NLL train/dev và dev BLEU. Đường nét đứt ở biểu đồ NLL là train.

5.3 Thời gian và số tham số

Bảng 5: Chi phí train đo trên T4. Không bao gồm validation và lưu checkpoint.

Mô hình	Tham số	Tổng train (giây)	Train/epoch TB (giây)
Transformer	39.737.344	4.282,43	142,75
Seq2Seq	20.005.889	3.825,89	255,06

Trong hai run này, phần train mỗi epoch của Transformer nhanh hơn khoảng 1,79 lần, dù số tham số lớn hơn khoảng 1,99 lần. Tuy nhiên tổng train Transformer là 71,37 phút, cao

hơn 63,76 phút của Seq2Seq vì chạy 30 thay vì 15 epoch. Không được dùng các con số train thuần để đại diện cho toàn bộ thời gian từ setup đến test.

Các tối ưu attention và AMP góp phần thay đổi cách thực thi, nhưng chưa có ablation tách riêng từng yếu tố. Bộ kết quả hiện tại chưa có benchmark latency suy luận; báo cáo không điền số latency từ bài mẫu hoặc dùng thời gian train để suy ra tốc độ dịch.

6. Phân tích bản dịch và thảo luận

Các ví dụ dưới đây lấy từ output test trong hai notebook. Dấu cách quanh dấu câu được thu gọn khi trình bày; nội dung bản dịch được giữ nguyên. Đây là phân tích sau khi chốt mô hình, không dùng để điều chỉnh hyperparameter theo test.

6.1 Câu ngắn: đúng nghĩa dù khác bản tham chiếu

Nguồn: And I was very proud.

Tham chiếu: Tôi đã rất tự hào về đất nước tôi.

Cả hai mô hình: Và tôi rất tự hào.

Bản dịch giữ được nghĩa trực tiếp của câu nguồn, dù không có cụm "về đất nước tôi" xuất hiện trong tham chiếu. Ví dụ cho thấy một tham chiếu duy nhất không bao phủ mọi cách diễn đạt phù hợp; khác chuỗi từ không đồng nghĩa với sai nghĩa hoàn toàn.

6.2 Từ đa nghĩa: Transformer không luôn tốt hơn

Nguồn: When I was seven years old, I saw my first public execution, but I thought my life in North Korea was normal.

Transformer, beam 5: Khi tôi lên 7 tuổi, tôi nhìn thấy cuộc điều hành công cộng đầu tiên của mình, nhưng tôi nghĩ cuộc sống của tôi ở Bắc Triều Tiên là bình thường.

Seq2Seq, beam 5: Khi tôi 7 tuổi, tôi thấy cuộc hành quyết công cộng đầu tiên, nhưng tôi nghĩ cuộc sống của mình ở Bắc Triều tiên là bình thường.

Transformer dịch "execution" thành "điều hành", sai nghĩa trong ngữ cảnh hành quyết. Seq2Seq chọn được từ "hành quyết", dù cụm "công cộng" còn kém tự nhiên hơn "công khai". Điểm BLEU toàn tập cao hơn không bảo đảm Transformer tốt hơn ở mọi mẫu.

6.3 Beam search có thể làm hỏng một câu cụ thể

Nguồn: But one day, in 1995, my mom brought home a letter from a coworker's sister.

Seq2Seq, greedy: Nhưng một ngày, vào năm 1995, mẹ tôi mang lại một lá thư từ chị gái của một người đồng nghiệp.

Seq2Seq, beam 5: Nhưng một ngày, vào năm 1995, mẹ tôi mang lại một lá thư từ chị gái của bò bò.

Greedy giữ được quan hệ "coworker's sister", còn beam 5 sinh cụm vô nghĩa "bò bò". Beam tối ưu điểm xác suất của mô hình, không trực tiếp tối ưu độ đúng ngữ nghĩa. Vì vậy mức tăng BLEU trung bình cần được đọc cùng phân tích lỗi cụ thể.

6.4 Tên riêng và sắc thái diễn đạt

Trong câu đầu của tập test, cả hai hệ thống còn để lại "Envy" trong tên bài hát "Nothing To Envy", đồng thời dịch đất nước tốt nhất thành "người giỏi nhất" hoặc "người tốt nhất". BPE làm giảm lệ thuộc vào từ vựng nguyên từ, nhưng không tự bảo đảm hiểu đúng tên riêng hoặc lựa chọn nghĩa theo ngữ cảnh.

7. Phân tích và nhận xét

7.1 Hiệu năng và quy mô mô hình

Trong thiết lập huấn luyện từ đầu trên IWSLT 2015 En→Vi, Transformer đạt 29,78 BLEU với beam search kích thước 5, cao hơn 1,60 điểm so với Seq2Seq kết hợp Luong Attention (28,18 BLEU). Tuy nhiên, Transformer có khoảng 39,7 triệu tham số, gần gấp đôi Seq2Seq với 20,0 triệu tham số.

Kết quả cho thấy sự đánh đổi giữa chất lượng dịch và quy mô mô hình: Seq2Seq sử dụng ít hơn khoảng 49,6% tham số nhưng vẫn đạt kết quả tương đối gần Transformer. Số tham số chưa đủ để kết luận về bộ nhớ hay độ trễ suy luận; các tiêu chí này cần được đo riêng.

7.2 Diễn biến huấn luyện

Seq2Seq đạt dev BLEU tốt nhất tại epoch 10 và dừng tại epoch 15 theo cơ chế early stopping với `patience = 5`. Transformer đạt dev BLEU tốt nhất tại epoch 28 trong tổng số 30 epoch.

Như vậy, Seq2Seq đạt checkpoint được chọn sớm hơn theo số epoch trong thí nghiệm này. Tuy nhiên, sự khác biệt còn chịu ảnh hưởng của optimizer, lịch learning rate và cấu hình mô hình, nên chưa thể quy hoàn toàn cho kiến trúc LSTM hay Transformer.

Việc Seq2Seq dừng sớm cho biết dev BLEU không cải thiện trong 5 epoch liên tiếp sau epoch tốt nhất. Riêng quan sát này chưa đủ để kết luận mô hình bị overfitting hoặc xác định nguyên nhân là learning rate cố định.

7.3 Ảnh hưởng của beam search

Khi chuyển từ greedy decoding sang beam search kích thước 5, BLEU của Transformer tăng từ 28,63 lên 29,78, còn Seq2Seq tăng từ 26,83 lên 28,18. Tính trên các giá trị chưa làm tròn, mức tăng tương ứng khoảng 1,15 và 1,36 BLEU.

Kết quả cho thấy cả hai mô hình đều hưởng lợi từ việc mở rộng không gian tìm kiếm khi giải mã. Seq2Seq có mức cải thiện lớn hơn trong thiết lập này, nhưng kết quả chưa đủ để xác định nguyên nhân ở từng thành phần kiến trúc hoặc từng bước dự đoán token.

7.4 Thời gian huấn luyện

Thời gian train trung bình mỗi epoch của Transformer khoảng 143 giây, thấp hơn Seq2Seq với khoảng 255 giây; tương ứng, Seq2Seq chậm hơn khoảng 1,79 lần. Các số liệu này không bao gồm thời gian đánh giá trên tập dev và lưu checkpoint.

Khả năng xử lý song song theo vị trí của Transformer trong quá trình huấn luyện là một yếu tố có thể góp phần tạo ra khác biệt. Ngoài ra, cách triển khai và chế độ tính toán cũng ảnh hưởng đến tốc độ, nên không thể quy toàn bộ chênh lệch thời gian cho kiến trúc.

Tổng thời gian train thực tế của Transformer khoảng 71,37 phút, cao hơn Seq2Seq với khoảng 63,76 phút, do Transformer được huấn luyện 30 epoch trong khi Seq2Seq dừng sau 15 epoch. Vì vậy, cần phân biệt tốc độ mỗi epoch với tổng chi phí của một lần huấn luyện.

7.5 Giới hạn của kết quả

Mỗi mô hình mới được chạy với một seed cố định (`seed = 42`), do đó chưa đánh giá được độ biến thiên giữa các lần huấn luyện. Chênh lệch 1,60 BLEU là kết quả quan sát được trong hai lần chạy này; chưa có đủ bằng chứng để kết luận về ý nghĩa thống kê của chênh lệch đó.

Dữ liệu còn có 12 cặp câu trùng giữa train và test theo phép so khớp chuỗi sau `strip`. Ảnh hưởng của phần dữ liệu trùng này chưa được định lượng. Một đánh giá bổ sung trên phần test không trùng với train có thể giúp làm rõ mức độ ảnh hưởng, đồng thời cần báo cáo riêng với kết quả trên toàn bộ tập test.

Kết quả chrF2 có cùng thứ hạng với BLEU, cung cấp thêm một góc nhìn nhất quán về chất lượng đầu ra. Tuy nhiên, sự đồng thuận giữa hai chỉ số tự động chưa thay thế được việc đánh giá thủ công về độ chính xác ngữ nghĩa, tính đầy đủ và độ tự nhiên của bản dịch.

7.6 Hướng phát triển

Các thí nghiệm tiếp theo có thể tập trung vào những hướng sau:

- **Khảo sát tokenizer và kích thước vocabulary.** So sánh cấu hình BPE 8.000 token mỗi phía với các kích thước khác hoặc vocabulary dùng chung giữa hai ngôn ngữ. Tăng

vocabulary không mặc nhiên cải thiện chất lượng; cần đánh giá sự đánh đổi giữa độ dài chuỗi, số tham số và khả năng học các token ít xuất hiện.

- **Khảo sát lịch learning rate cho Seq2Seq.** Thử giảm learning rate theo tiến trình huấn luyện hoặc theo kết quả trên tập dev, thay vì giữ learning rate cố định. Hiệu quả của thay đổi này cần được kiểm chứng bằng thực nghiệm.
- **Bổ sung và kiểm soát chất lượng dữ liệu.** Mở rộng dữ liệu song ngữ đi kèm với lọc chất lượng, kiểm tra trùng lặp và xem xét sự phù hợp miền dữ liệu với bài toán dịch đang đánh giá.
- **Tăng độ tin cậy của đánh giá.** Huấn luyện với nhiều seed, báo cáo trung bình và độ phân tán của kết quả, đồng thời bổ sung đánh giá thủ công và kiểm định thống kê phù hợp.
- **Đo chi phí suy luận.** Đánh giá bộ nhớ sử dụng, độ trễ và thông lượng khi dịch với cùng phần cứng, batch size và cấu hình giải mã, nhằm so sánh khả năng triển khai của hai mô hình.

Mọi lựa chọn cấu hình cần dựa trên tập dev. Tập test được giữ lại cho đánh giá cuối cùng, tránh sử dụng kết quả test để điều chỉnh siêu tham số.

8. Tổ chức bài nộp

Mã nguồn GitHub: 24022321_ASM-Machine-Translation

Tài liệu và kết quả thực nghiệm: Google Drive

Để tạo lại bảng kết quả từ hai run đã đánh giá, chạy từ thư mục gốc project:

```
python compare.py -runs runs/transformer runs/seq2seq
  -output-dir comparison -plots
```

Đường dẫn cần đổi theo vị trí checkpoint thực tế. `best.pt` dùng để đánh giá; `last.pt` dùng để resume. Các file cấu hình, fingerprint, lịch sử và metric phải được giữ để kết quả có thể kiểm tra lại.

Tài liệu

[1] A. Vaswani và cộng sự. *Attention Is All You Need*. 2017. `https://arxiv.org/abs/1706.03762`.

[2] M.-T. Luong, H. Pham, C. D. Manning. *Effective Approaches to Attention-based Neural Machine Translation*. EMNLP, 2015. `https://aclanthology.org/D15-1166/`.

[3] TensorFlow. *Neural Machine Translation Tutorial*. `https://github.com/tensorflow/nmt`.

[4] M. Post. *A Call for Clarity in Reporting BLEU Scores*. WMT, 2018. https://aclanthology.org/W18-6319/.

[5] Google. *SentencePiece*. Thư viện sử dụng trong project. https://github.com/google/sentencepiece.

[6] *demo_ transformer.ipynb*. Notebook được cung cấp trong đề bài ASM Machine Translation.